

Laporan Praktikum Kontrol Cerdas- Week 4

Nama : Muhammad Sadiqih Asbullah

NIM 224308016

Kelas : TKA-6A

Akun Github (Tautan) : <https://github.com/Sadiqih>

Student Lab Assistant : Muhammad Faiq

1. Judul Percobaan

Melatih dan Menguji Agen Reinforcement Learning Untuk Mengontrol Lingkungan Secara Otonom

2. Tujuan Percobaan

Tujuan dari percobaan pada praktikum kali ini, sebagai berikut:

1. Mahasiswa dapat memahami Konsep dasar dari Reinforcement Learning (RL) dalam sistem kendali.
2. Mahasiswa dapat mengetahui cara mengimplementasikan RL menggunakan algoritma Deep Q-Network (DQN).
3. Mahasiswa dapat mengetahui bagaimana melatih dan menguji agen RL untuk mengontrol lingkungan secara otonom.

3. Landasan Teori

Reinforcement Learning (RL) adalah salah satu pendekatan dalam pembelajaran mesin yang memungkinkan agen belajar melalui interaksi dengan lingkungan untuk memaksimalkan reward kumulatif. Agen dalam RL mengambil tindakan berdasarkan kebijakan (policy) tertentu, kemudian menerima umpan balik dalam bentuk reward dari lingkungan, yang digunakan untuk memperbarui strategi pengambilan keputusan. Metode RL sering diformulasikan dalam kerangka Markov Decision Process (MDP) yang terdiri dari himpunan state (S), action (A), reward function (R), dan transition probability (P). Algoritma RL dapat dikategorikan menjadi dua jenis utama, yaitu model-based (agen membangun model lingkungan) dan model-free (agen belajar langsung dari pengalaman). Beberapa algoritma populer dalam RL termasuk Q-Learning, Deep Q-Networks (DQN), Policy Gradient, dan Proximal Policy Optimization (PPO). RL banyak diterapkan dalam berbagai bidang, seperti robotika, permainan (game AI), sistem rekomendasi, dan kendali adaptif dalam sistem otomatisasi (Sutton & Barto, 2018).

4. Analisis & Diskusi

Pada percobaan kali ini, saya melakukan percobaan dengan VsCode untuk program Reinforcement Learning menggunakan simulasi pada pygame. Di mana saya melatih program

DQN atau Deep Q-Network (DQN) sebagai algoritma dari sistemnya dengan jumlah 50 episode, kemudian saya menjalankan program testing untuk melihat hasil dari pelatihannya. Pada hasil tampak bila tongkat beberapa kali bergerak namun kembali ke posisi semula dengan siklus yang cukup cepat, terlihat bila pada dasar tongkat berusaha untuk menstabilkan agar tongkat tetap tegak. Namun untuk membuat hasil lebih baik lagi dapat dengan mengubah nilai dari Gamma, Epsilon, ataupun Learning Rate. Bila nilai gamma tinggi, agen akan lebih fokus pada reward jangka panjang, yang bisa membuat pembelajaran lebih stabil. Sebaliknya, kalau gamma rendah, agen lebih memilih untuk reward instan, jadi proses learningnya lebih cepat. Untuk epsilon, kalau nilainya tinggi, agen akan lebih sering mencoba aksi secara acak (eksplorasi), yang bagus pada tahap awal training. Namun kalau epsilon rendah, agen lebih sering memilih aksi terbaik (eksploitasi), jadi akan lebih cocok untuk tahap akhir training. Sedangkan untuk learning rate, kalau terlalu tinggi, agen bisa belajar dengan cepat, tapi risikonya jadi kurang stabil dan bisa overfitting. Sebaliknya, kalau terlalu rendah, belajar jadi lebih lambat, tapi lebih stabil dan bisa meningkatkan performa dalam jangka panjang. Selanjutnya pada tantangan yang muncul yaitu menentukan nilai dari parameter-parameter yang dapat mempengaruhi hasil dan juga proses training yang cukup menguras waktu.



Diskusi

1. Pada Reinforcement Learning, datasetnya merupakan eksplorasi data dari hasil training pada data dipelajari dengan trial and error, sehingga sistem akan mengoptimalkan hasilnya dengan terus beradaptasi dengan umpan balik yang diberikan, namun bila pada supervised learning datasetnya menggunakan dataset berlabel yang sudah diberikan referensi terkait outputnya sehingga SL bekerja dengan menyocokkan hasil deteksinya dengan data yang diberikan sebagai trainingnya.
2. Dapat dilakukan dengan mengoptimalkan nilai Gamma, Epsilon dan Learning Rate agar program dapat mengeksplorasi dan mempelajari data lebih optimal.
3. Dari sepehaman saya program ini dapat diaplikasikan pada dunia robot yang memiliki penggunaan pada adaptasi dan memori yang dialami robot pada setiap beroperasi, sehingga robot dapat bertindak sesuai dengan eksplorasi dan learning data yang telah dilaluinya.

5. Assignment

Pada program selanjutnya yaitu saya mengubah yang sebelumnya untuk simulasi tongkat yang berdiri tegak menggunakan Target network dengan jumlah episode 1000, dari hasil percobaannya menunjukkan bila tongkat lebih stabil dari yang sebelumnya karena terdapat parameter tambahan untuk melakukan adaptasi data dan episode yang lebih banyak sehingga jangkauan untuk learningnya menjadi lebih luas. Pada program mountain car, di mana terdapat mobil yang diletakkan pada lintas Lembah dan gunung. Pada percobaan pertama saya mencoba dengan 50 episode, hasilnya mobil tidak begitu mampu untuk menanjak, setelahnya saya mengubah menjadi 1000 episode dan hasilnya mobil cukup mampu untuk menanjak lebih tinggi lagi, hal ini berkaitan dengan data latih dari setiap uji coba mobil untuk dapat menanjak. Kemudian saya juga mencoba mengubah beberapa parameter yang lain dan terjadi beberapa perbedaan dari hasil Gerakan mobil, seperti mundur lebih jauh, naik cukup tinggi dan lain sebagainya.

6. Data dan Output Hasil Pengamatan

NO	Variabel	Hasil Pengamatan
1	Tongkat	
2	Mountain Car	

7. Kesimpulan

Dari hasil percobaan yang saya buat, dapat disimpulkan bahwa pada program RL memiliki sistem latih data yang lebih kompleks karena program dilakukan dengan trial and error sehingga kita mencoba untuk menentukan beberapa parameter yang tepat agar hasilnya optimal.

8. Saran

Untuk penelitian mendatang dapat dilakukan percobaan untuk membuat penerapannya pada hardware.

9. Daftar Pustaka

Sutton, R. S., & Barto, A. G. (2018). Reinforcement Learning: An Introduction (2nd ed.). MIT Press.

Kaelbling, L. P., Littman, M. L., & Moore, A. W. (1996). "Reinforcement Learning: A Survey." Journal of Artificial Intelligence Research, 4, 237-285.

Mnih, V., Kavukcuoglu, K., Silver, D., Rusu, A. A., et al. (2015). "Human-level Control through Deep Reinforcement Learning." Nature, 518(7540), 529-533.